Manual de Usuario: Agente de IA para RAG en n8n

Juan David Torres Avila

06/06/2025

1. Propósito

Este flujo de trabajo permite a un agente de inteligencia artificial (IA) responder preguntas en base al contenido de un documento de texto utilizando Recuperación Aumentada por Generación (RAG). Se emplean las siguientes tecnologías:

- Qdrant como vector store.
- Ollama para generación de texto e incrustaciones (embeddings).
- n8n como orquestador del flujo.

2. Instalación de Dependencias

Para ejecutar correctamente el agente de IA RAG, deben instalarse las siguientes herramientas: **Docker**, **Qdrant**, **n8n** y **Ollama**. A continuación, se detallan los pasos para la instalación de cada una:

2.1. Instalar Docker

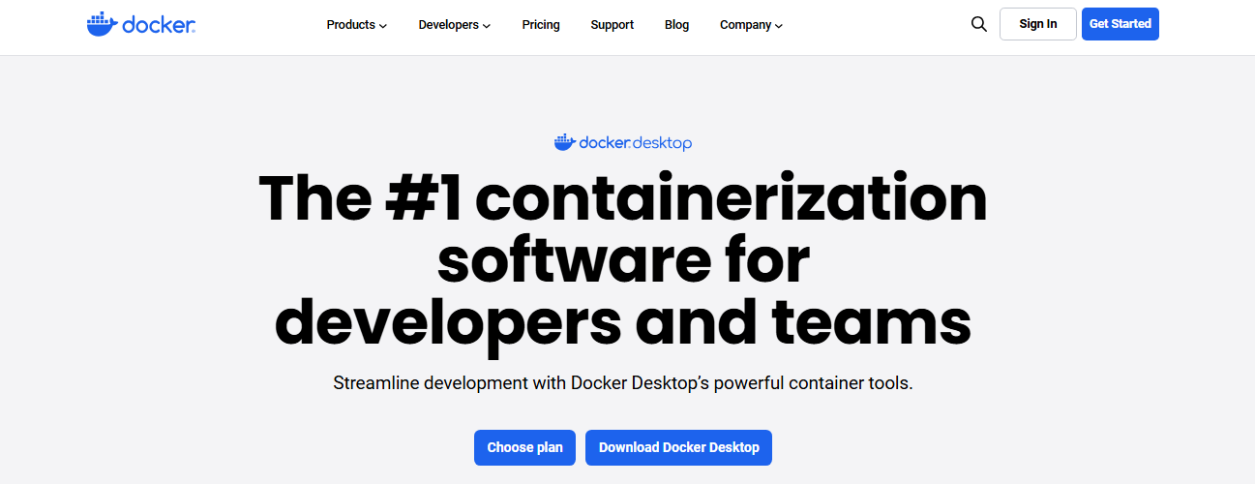

1. Ir a `https://www.docker.com/products/docker-desktop`
2. Descargar Docker Desktop según su sistema operativo (Windows, macOS o Linux).
3. Ejecutar el instalador y seguir las instrucciones.
4. Verificar la instalación con el siguiente comando en una terminal:

   ```
   docker --version
   ```

2.2. Instalar Qdrant

1. Ejecutar el siguiente comando en una terminal para iniciar Qdrant usando Docker:

   ```
   docker run -p 6333:6333 -p 6334:6334 qdrant/qdrant
   ```

2. Qdrant quedará accesible por los puertos 6333 (API) y 6334 (dashboard).

2.3. Instalar n8n

Opción 1: Usando Docker

```
docker run -it --rm \
  -p 5678:5678 \
  -v ~/.n8n:/home/node/.n8n \
  n8nio/n8n
```

Opción 2: Usando npm

1. Instalar Node.js (recomendado: versión 18.x).
2. Ejecutar los siguientes comandos:

   ```
   npm install -g n8n
   n8n
   ```

2.4. Instalar Ollama

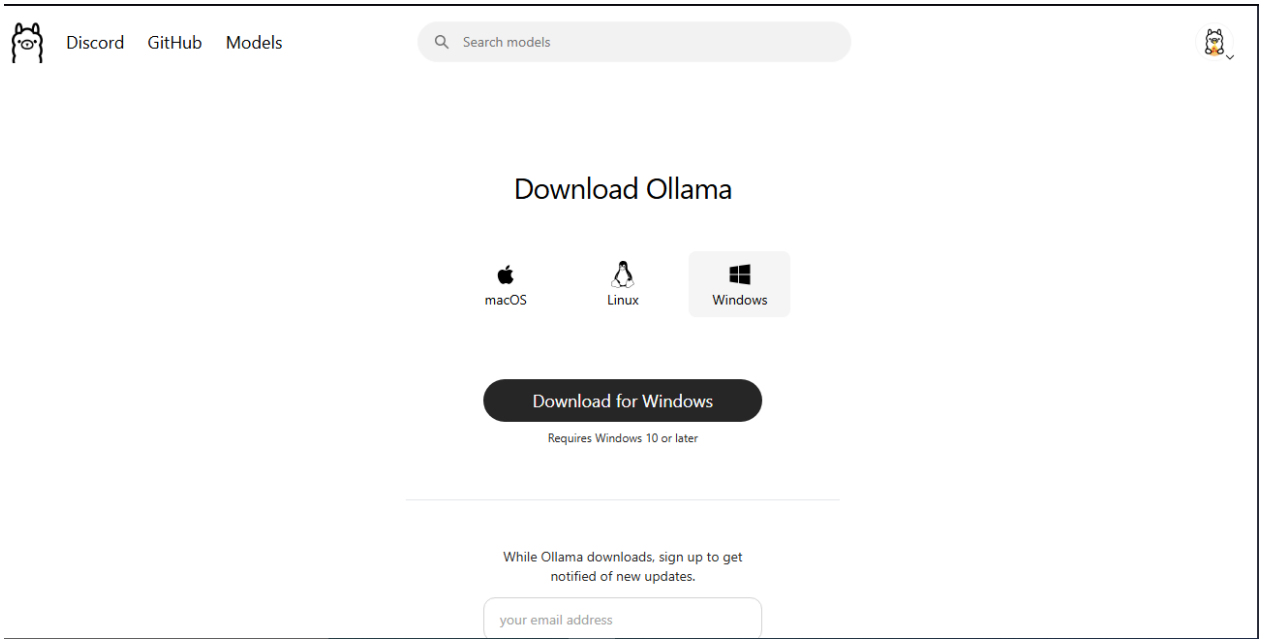

1. Ir a `https://ollama.com/download`
2. Descargar el instalador para su sistema operativo.
3. Instalar y ejecutar Ollama.
4. Verificar funcionamiento con el siguiente comando:

   ```
   ollama run llama3
   ```

Una vez completadas estas instalaciones, verifique que cada herramienta funcione correctamente antes de continuar con la configuración del flujo.

3. Requisitos Previos

Para la correcta ejecución del flujo, asegúrese de tener:

- Una cuenta y credenciales configuradas para:
  - Qdrant
  - Ollama
  - OpenIA (Opcional)

- Archivo de texto cargado localmente o archivo con el formato seleccionado en el Default Data Loader (nodo en el flujo de trabajo de n8n).

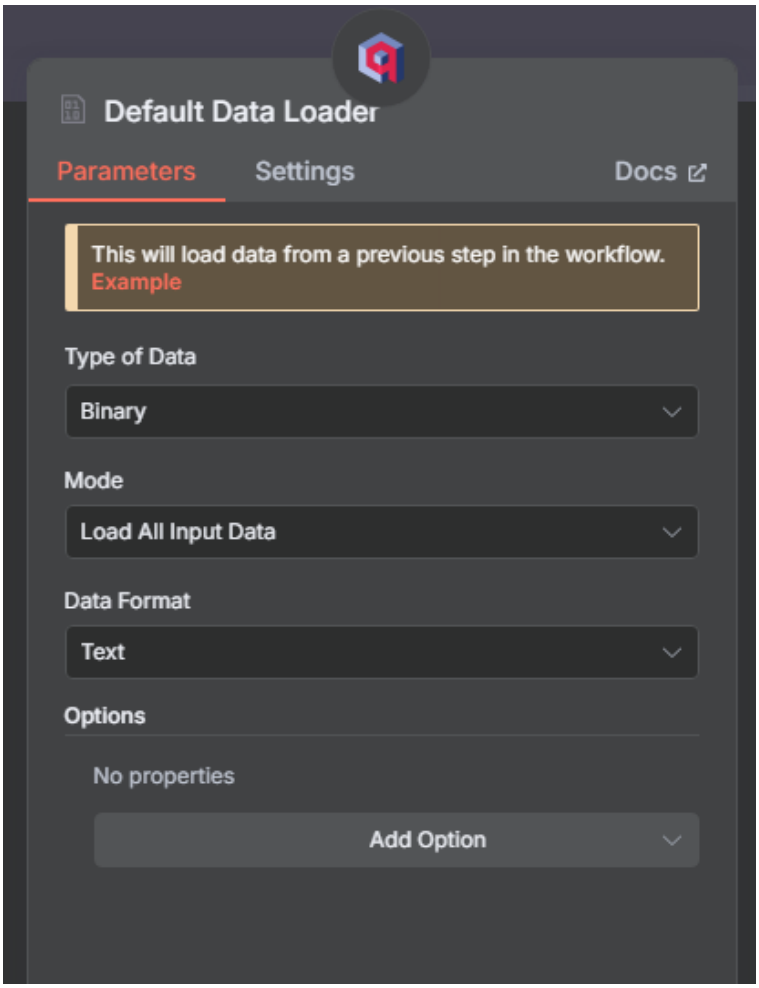

(Nodo donde se configura el tipo de dato esperado)

- Las credenciales conectadas en n8n:
  - `QdrantApi account`
  - `Ollama account`
  - `Modelo de Ollama que dese utilizar`
  - `Modelo para el embedding con Ollama`

4. Estructura del Flujo

4.1. Carga y procesamiento del documento

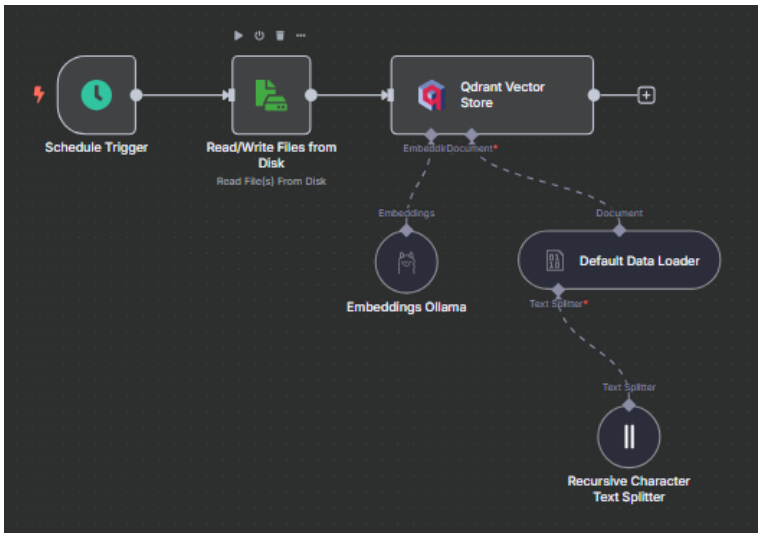

- **Schedule Trigger**: Dispara el flujo automáticamente en un intervalo definido.
- **Read/Write Files from Disk**: Lee el archivo desde el disco en la ruta: `D:\Descargas\Codigo 2\Prueba-datos\inteligencia_artificial.txt`.
- **Embeddings Ollama**: Convierte el texto en vectores usando el modelo `nomic-embed-text`.
- **Default Data Loader**: Carga los datos como documentos compatibles.
- **Recursive Character Text Splitter**: Divide el texto en fragmentos de 800 caracteres con un solapamiento de 100.
- **Qdrant Vector Store**: Inserta los vectores en la colección `Prueba-datos`.

4.2. Carga y procesamiento del documento (forma alterna, fuera del flujo)

Importación de librerías

```
import openai
from qdrant_client import QdrantClient
from qdrant_client.models import VectorParams, Distance, PointStruct
import PyPDF2
```

Estas librerías permiten leer PDFs, conectarse a Qdrant y usar los embeddings de OpenAI.

Configuración de API y parámetros globales

```
openai.api_key = "sk-proj-..."

QDRANT_URL = "http://localhost:6333"
COLLECTION_NAME = "documentos_pdf"
EMBEDDING_MODEL = "text-embedding-3-small"
VECTOR_SIZE = 1536
```

Se define la clave de API de OpenAI, URL de Qdrant, nombre de colección, modelo y tamaño de vectores.

Lectura de PDF

```
def leer_pdf(path):
    with open(path, "rb") as f:
        reader = PyPDF2.PdfReader(f)
        texto = "".join([p.extract_text() for p in reader.pages if p.extract
    return texto
```

Extrae el texto de cada página de un archivo PDF.

División del texto

```
def dividir_texto(texto, tamaño=500):
    return [texto[i:i+tamaño] for i in range(0, len(texto), tamaño)]
```

Divide el texto completo en fragmentos de tamaño especificado (500 por defecto).

Obtención de embeddings

```
def obtener_embeddings(textos):
    response = openai.embeddings.create(model=EMBEDDING_MODEL, input=textos)
    return [r.embedding for r in response.data]
```

Usa OpenAI para convertir texto en vectores numéricos (embeddings).

Subida a Qdrant

```
def subir_a_qdrant(vectores, textos):
    client = QdrantClient(url=QDRANT_URL)
    if not client.collection_exists(COLLECTION_NAME):
        client.recreate_collection(
            collection_name=COLLECTION_NAME,
```

```
            vectors_config=VectorParams(size=VECTOR_SIZE, distance=Distance.C
        )
    puntos = [PointStruct(id=i, vector=v, payload={"texto": textos[i]}) for i
    client.upsert(collection_name=COLLECTION_NAME, points=puntos)
    print(f"{len(puntos)} fragmentos subidos a Qdrant.")
```

Crea una colección si no existe, estructura los puntos y los sube a Qdrant.

Bloque principal

```
if __name__ == "__main__":
    texto = leer_pdf("documento.pdf")
    fragmentos = dividir_texto(texto)
    embeddings = obtener_embeddings(fragmentos)
    subir_a_qdrant(embeddings, fragmentos)
```

Ejecuta todas las funciones: lectura, división, embeddings y subida a Qdrant.

Comando de ejecución

Para ejecutar el codigo anterior, desde PowerShell con Direccion de la carpeta:
`cd "C:\Users\Cornifer\Downloads"`(Ejemplo de una dirección de carpeta)
Archivo de codigo pythom con el progrma anteriormente explicado:
`python cargar_txt_a_qdrant_ruta_personalizada.py`

4.3. Interacción del usuario

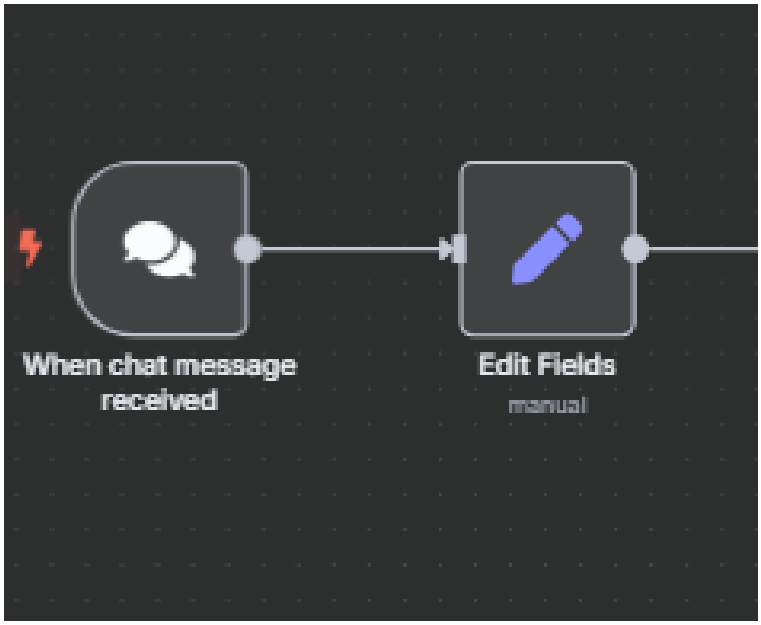

- **When chat message received**: Captura el input del usuario.
- **Edit Fields**: Asigna y normaliza los campos `chatInput` y `sessionId`.

4.4. 3. Agente Inteligente RAG

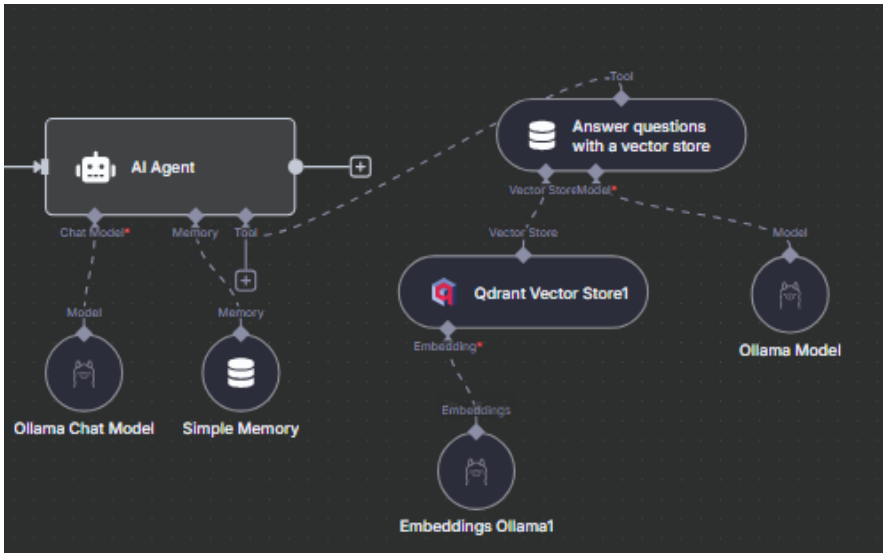

- **Ollama Chat Model**: Modelo conversacional.
- **Simple Memory**: Guarda el historial de conversación con clave personalizada.
- **Qdrant Vector Store1**: Realiza búsqueda de contexto en la colección `ia_txt`.
- **Embeddings Ollama1**: Genera vectores para la consulta del usuario.
- **Ollama Model**: LLM que responde usando el contexto encontrado.
- **Answer questions with a vector store**: Herramienta que consulta el vector store.
- **AI Agent**: Une todos los componentes para generar respuestas con contexto.

5. Ejecución del Flujo

A. Manual

Ejecute abriendo el chat del flujo y empezando con la interacción o desde cualquier punto del flujo (para probar los diferentes nodos).

B. Automática (API o Webchat)

Envíe una solicitud POST al webhook generado por el nodo `When chat message received` con la siguiente estructura:

```
{
  "chatInput": " Que es la inteligencia artificial?",
  "sessionId": "usuario123"
}
```

6. Resultado Esperado

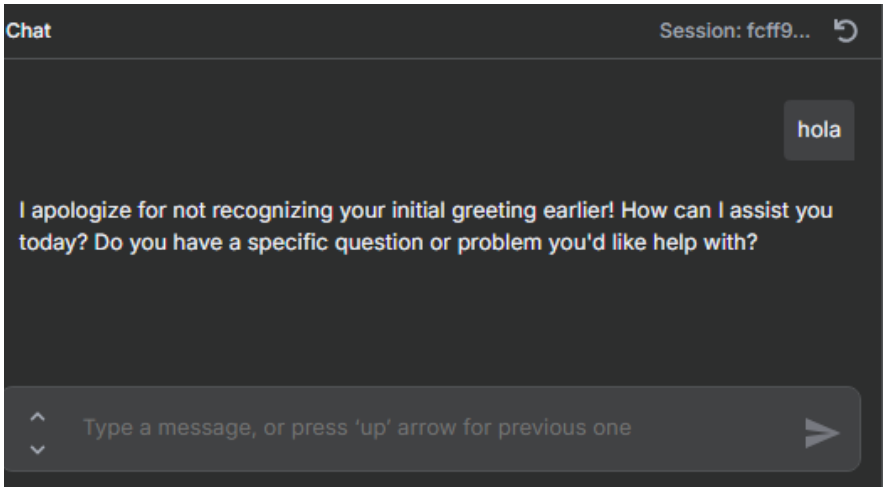

El agente IA responderá basándose en la información contenida en el documento, consultando el vector store con embeddings y generando una respuesta contextual con Ollama.

7. Notas Técnicas

- El texto se divide en fragmentos para mejorar la eficiencia semántica.
- Se emplea memoria conversacional para mantener el contexto.
- Asegúrese que la coleccion`ia_txt` estén creadas en Qdrant.